Questão 2 — Estudo por Inquérito: Entrega de Refeições ao Domicílio

Dados do Problema e Preparação

Amostra inicial: n = 350 clientes. Taxa de não-resposta ≈ 15%, logo o número de não-respondentes é 350 × 0,15 = 52. Número de respondentes efectivos é n = 350 − 52 = 298 clientes. Dos 298 respondentes: 35 clientes auferiram o salário mínimo de 970 €, e para os restantes 263 clientes: $\sum x_i$ = 329 500 €. Soma total: $\sum x_i$ = 35 × 970 + 329 500 = 33 950 + 329 500 = 363 450 € Média amostral: $\bar{x}$ = 363 450 / 298 ≈ 1 219,63 € Variância amostral fornecida: s^2 = 10 080 €², logo s ≈ 100,40 €

Nota: O enunciado indica que s^2 = 10 080 foi obtido "para a amostra global" (n = 350). Assume-se, como hipótese de trabalho, que este valor representa a variabilidade da variável em estudo e se utiliza como estimativa de σ^2 para os 298 respondentes. (Se s^2 se referisse estritamente aos 350 inquiridos, ter-se-ia SE = √(10 080/350) = 5,367 e E = 10,52, obtendo-se IC ≈ [1 209,11; 1 230,15]; a conclusão qualitativa mantém-se.)

a) Intervalo de Confiança a 95% — AAS (população grande/infinita)

Justificação das opções metodológicas

Utiliza-se a Amostragem Aleatória Simples (AAS). Como a população de clientes é desconhecida (ou muito grande), não se aplica o factor de correcção para população finita. A taxa de não-resposta de 15% é tratada pela análise completa (complete-case analysis): trabalha-se com os n = 298 respondentes, assumindo que a não-resposta é aleatória (MCAR) e que a amostra efectiva continua representativa. Como n = 298 ≫ 30, pelo Teorema do Limite Central, a distribuição da média amostral é aproximadamente normal. Usa-se $z_{0,025}$ = 1,96 para o nível de confiança de 95%.

Limitação: Esta análise distingue erro de amostragem de enviesamento por não-resposta. A redução de n aumenta a incerteza, mas não permite avaliar diferenças sistemáticas entre respondentes e não-respondentes. A hipótese MCAR é assumida como limitação metodológica, pois não dispomos de informação para a verificar.

Cálculo do Intervalo de Confiança

Erro padrão da média: SE = √(s^2/n) = √(10 080 / 298) = √33,826 ≈ 5,816 €

Margem de erro (E): E = z × SE = 1,96 × 5,816 ≈ 11,40 €

Intervalo de Confiança a 95%: $IC_{95}\%$ = [$\bar{x}$ − E ; $\bar{x}$ + E] = [1 219,63 − 11,40 ; 1 219,63 + 11,40]

$IC_{95}\%$ ≈ [1 208,23 € ; 1 231,03 €]

Comentário à margem de erro

A margem de erro obtida é E ≈ 11,40 €, representando cerca de 0,93% da média estimada (1 219,63 €). Trata-se de uma margem de erro bastante reduzida, indicando uma estimativa com boa precisão. A amostra de 298 respondentes, conjugada com uma variância s^2 = 10 080 €² (desvio-padrão ≈ 100,40 €), permite obter um IC bastante estreito. A tolerância/precisão da estimativa (sinónimos: margem de erro, erro máximo da estimativa) é aqui satisfatória para fins práticos de gestão da plataforma.

b) Procedimento para N = 800 clientes (população finita)

Quando a população é conhecida e finita (N = 800), é necessário verificar se a taxa de amostragem f = n/N é significativa. Convencionalmente, se f > 5%, aplica-se o Factor de Correcção para Populações Finitas (fcp): fcp = √[(N − n) / (N − 1)]

Com N = 800 e n = 298: f = 298/800 ≈ 37,2% > 5%, portanto a correcção é recomendada.

Cálculo: fcp = √[(800 − 298) / (800 − 1)] = √[502 / 799] = √0,6283 ≈ 0,7927

O fcp pressupõe um desenho de amostragem aleatória simples sem reposição. A correção reduz a variância por cobrirmos 37,2% da população, mas não elimina eventual enviesamento associado à não-resposta.

SE_{corr}= √(s^2/n) × fcp = 5,816 × 0,7927 ≈ 4,610 €

E_{corr}= 1,96 × 4,610 ≈ 9,04 € IC_{95}% (N=800) ≈ [1 210,59 € ; 1 228,67 €]

Interpretação: A margem de erro reduz de 11,40 € para 9,04 €. Isto é esperado: ao amostrar uma fracção grande (37,2%) de uma população pequena, a incerteza é proporcionalmente menor, pois "cobrimos" uma parte substancial da população. O fcp introduz esta redução de variância — quanto maior f, maior a redução da margem de erro.

c) Tipo de Amostragem e Cálculo do Tamanho da Amostra para a Satisfação

Tipo de amostragem recomendado

Face à divisão natural do país em duas regiões (A e B), o método mais adequado é a Amostragem Aleatória Estratificada. Este método:

> Garante representação proporcional (ou óptima) de ambas as regiões;

> Reduz a variância da estimativa global comparativamente à AAS;

> É o método que proporciona melhores propriedades estatísticas quando existem subgrupos homogéneos internamente (como regiões geográficas);

> Permite estimativas separadas por estrato, úteis para decisões logísticas.

Os estratos são: Estrato A: N_A = 22 500 clientes e Estrato B: N_B = 19 400 clientes (total N = 41 900).

Cálculo do tamanho total da amostra

Para uma variável de proporção (satisfação: sim/não), sem estimativa prévia de p, usa-se o caso conservador p = q = 0,5 (maximiza a variância). Para confiança de 95%: z = 1,96. Admite-se uma margem de erro e = 5% (valor convencional para estudos de satisfação). Sem correcção finita (fórmula base):

$n_0 = z^2 \times p \times q / e^2 = (1,96)^2 \times 0,5 \times 0,5 / (0,05)^2 = 3,8416 \times 0,25 / 0,0025 \approx 385$

Com correcção para população finita (N = 41 900 e n_0/N ≈ 0,9%, portanto o impacto é pequeno, mas rigoroso):

$n = n_0 / [1 + (n_0 - 1)/N] = 385 / [1 + 384/41\,900] \approx 385 / 1,00917 \approx 381$

Tamanho total da amostra: n = 381

O cálculo inicial n_0 corresponde à expressão habitual para estimação de uma proporção global (p=0,5 conservador). A eficiência do desenho estratificado depende da variabilidade dentro de cada estrato. Na ausência de informação sobre variâncias intra-estrato, utiliza-se a afetação proporcional.

Alocação proporcional ao tamanho dos estratos:

n_A = 381 × (22 500 / 41 900) = 381 × 0,537 ≈ 205 clientes

n_B = 381 × (19 400 / 41 900) = 381 × 0,463 ≈ 176 clientes

A alocação proporcional (afectação proporcional ao tamanho dos estratos) é a mais equilibrada quando não se conhece a variância intra-estrato. Se as variâncias intra-estrato fossem conhecidas, a alocação ótima de Neyman proporcionaria ainda maior eficiência.

d) Alternativas para IC não baseados na Teoria Clássica

A teoria clássica dos intervalos de confiança assenta em pressupostos paramétricos — tipicamente a normalidade da distribuição amostral (pelo TLC ou distribuição exacta). Quando esses pressupostos não se verificam — amostras pequenas, distribuições assimétricas, dados com outliers ou estimadores sem forma analítica conhecida — existem alternativas robustas:

1. Bootstrap (Reamostragem)

O bootstrap constrói IC empiricamente, sem assumir qualquer distribuição. A partir da amostra original, geram-se B reamostras com reposição (tipicamente B = 1 000–10 000), calcula-se a estatística de interesse em cada reamostra, e o IC é obtido pelos percentis da distribuição empírica (método percentil) ou por variantes mais precisas (BCa — bias-corrected and accelerated). Exemplo prático: estimar um IC para a mediana do rendimento mensal, cuja distribuição amostral não tem fórmula fechada simples.

2. Métodos Bayesianos

A abordagem Bayesiana substitui o IC por um Intervalo de Credibilidade, interpretado directamente como "a probabilidade de o parâmetro estar no intervalo é 95%". Combina uma distribuição a priori (conhecimento prévio) com a verosimilhança dos dados, obtendo a distribuição a posteriori do parâmetro. Exemplo prático: estimar a taxa de satisfação de clientes com poucos dados e incorporar estudos anteriores como priori informativa. Ambos os métodos são particularmente úteis em amostras pequenas, estimadores complexos ou distribuições não-normais, situações comuns em estudos de mercado e logística.

Referências: Lohr, S. L. (2021) Sampling: Design and Analysis; Cochran, W. G. (1977) Sampling Techniques, Cap. 5 (FCP) e Cap. 5A (Amostragem Estratificada).