UAb

MESTRADO EM ESTATÍSTICA, MATEMÁTICA E COMPUTAÇÃO (2026/2027)

UC: COMPUTAÇÃO ESTATÍSTICA I | 22008

ATIVIDADE FORMATIVA 1

Período de realização

Decorre de 27/10 a 2/11 de 2026

Iniciar no R

Tema: Programação, manipulação de dados e análise estatística com R

Objetivos de aprendizagem

No final desta atividade, espera-se que o estudante seja capaz de utilizar o R para resolver problemas computacionais de natureza estatística, construir algoritmos e funções reutilizáveis, explorar conjuntos de dados reais e avaliar criticamente os resultados obtidos.

A utilização de funções predefinidas é permitida, exceto quando expressamente indicado em contrário. Todas as soluções deverão ser acompanhadas de código R devidamente comentado.

UNIVERSIDADE AbERTA www.uab.pt

Grupo I — Fundamentos de programação e estruturas de dados

Exercício 1 — Operações vetorizadas e precisão numérica

Considere as expressões

$$A = \sum_{k=1}^{100} \frac{(-1)^{k+1}}{k}, \qquad B = \prod_{k=1}^{20} \left(1 + \frac{1}{k^2}\right)$$

e

$$C = \sum_{k=0}^{30} \frac{(-2)^k}{k!}$$

a) Calcule os valores de A, B e C, utilizando operações vetorizadas em R, sem recorrer a ciclos explícitos.

b) Compare o valor de A com $\log(2)$ e o valor de C com e^{-2}. Determine os erros absolutos e relativos.

c) Generalize o cálculo de A para uma soma de n parcelas, construindo uma função `soma_alternada(n)`.

d) Represente graficamente o erro absoluto de A, em função de n=1,…,1000, utilizando uma escala logarítmica no eixo vertical.

e) Explique por que razão a ordem das operações pode influenciar os resultados em aritmética de vírgula flutuante.

Exercício 2 — Vetores, indexação e estatísticas descritivas

Considere o vetor *x*, constituído pelos algarismos do seu número de estudante.

a) Construa o vetor automaticamente a partir do número de estudante, sem introduzir individualmente os algarismos.

b) Determine média, mediana, variância amostral, desvio-padrão, amplitude interquartil e coeficiente de variação, discutindo os casos em que este último não se encontra definido.

UNIVERSIDADE ABERTA www.uab.pt

c) Construa um novo vetor contendo apenas os elementos de x superiores à respetiva média.

d) Determine as frequências absolutas e relativas dos diferentes algarismos, incluindo os algarismos que não aparecem no vetor.

e) Construa uma função `estatisticas(x)` que devolva uma lista com as medidas calculadas na alínea b), sem recorrer a `summary()`.

f) Introduza artificialmente dois valores `NA` no vetor e adapte a função para tratar valores omissos.

g) Compare a variância amostral obtida através de `var()` com a calculada diretamente a partir da sua definição.

Exercício 3 — Sequências, matrizes e álgebra linear

Considere a matriz

$$A = \begin{pmatrix} 4 & 1 & 2 \\ 1 & 3 & -1 \\ 2 & -1 & 5 \end{pmatrix}$$

a) Introduza a matriz em R e determine a sua transposta, determinante, traço e valores próprios.

b) Verifique numericamente se A é simétrica e definida positiva.

c) Resolva o sistema linear $A\mathbf{x} = \mathbf{b}$, com $\mathbf{b} = (1,2,3)^T$, utilizando `solve()`.

d) Calcule o vetor de resíduos $A\hat{\mathbf{x}} - \mathbf{b}$ e a respetiva norma euclidiana.

e) Determine a decomposição de Cholesky de A e verifique a reconstrução da matriz original.

f) Construa uma função que receba uma matriz quadrada e determine se esta é simétrica e definida positiva, utilizando uma tolerância numérica explicitamente definida.

UNIVERSIDADE ABERTA www.uab.pt

Grupo II — Programação e tratamento de dados

Exercício 4 — Funções, algoritmos e controlo de fluxo

Pretende-se desenvolver uma função que calcule medidas estatísticas sem recorrer diretamente às funções estatísticas predefinidas.

a) Construa a função `media_manual(x)` utilizando um ciclo `for`.

b) Construa uma segunda versão utilizando operações vetorizadas.

c) Desenvolva uma função `variancia_manual(x)` que calcule a variância amostral e trate corretamente valores omissos.

d) Implemente uma função para calcular a mediana, recorrendo apenas à ordenação e à indexação.

e) Compare os resultados das funções desenvolvidas com `mean()`, `var()` e `median()`.

f) Compare o tempo de execução das duas versões da função de cálculo da média para vetores de dimensão 10^3, 10^5 e 10^6, utilizando `system.time()` e repetindo cada experiência pelo menos 20 vezes.

g) Discuta as vantagens e limitações da programação vetorizada em R.

Exercício 5 — Manipulação e limpeza de dados

Considere a base de dados `airquality`, disponível no R.

a) Identifique a estrutura da base de dados e o número de valores omissos por variável.

b) Determine a percentagem de observações incompletas.

c) Construa duas versões da base de dados: uma eliminando observações incompletas e outra substituindo os valores omissos das variáveis quantitativas pelas respetivas medianas.

d) Compare as médias, medianas e desvios-padrão das variáveis nas duas versões.

UNIVERSIDADE ABERTA www.uab.pt

e) Crie uma nova variável correspondente à temperatura em graus Celsius.

f) Identifique potenciais valores atípicos de `Ozone` através da regra de 1,5 x IQR.

g) Represente graficamente a distribuição de `Ozone` antes e depois do tratamento dos valores omissos.

h) Discuta de que forma as estratégias adotadas podem influenciar as conclusões estatísticas.

Exercício 6 — Manipulação avançada de data frames

Utilize a base de dados `mtcars`.

a) Crie uma variável que classifique os automóveis em três categorias de consumo, definidas a partir dos tercis de `mpg`.

b) Determine, para cada número de cilindros, a média, mediana e desvio-padrão de `mpg` e `hp`.

c) Identifique os automóveis com potência superior ao percentil 75 de `hp` e consumo inferior à mediana de `mpg`.

d) Construa uma tabela cruzada entre número de cilindros e categoria de consumo.

e) Determine a correlação entre `mpg`, `wt`, `hp` e `disp`, utilizando apenas observações completas.

f) Repita as operações das alíneas b) e c) utilizando `dplyr`.

g) Compare a legibilidade das soluções obtidas com R `base` e `dplyr`.

Grupo III — Visualização e modelação estatística

Exercício 7 — Visualização exploratória

Considere a base de dados `iris`.

UNIVERSIDADE AbERTA www.uab.pt

a) Construa uma matriz de gráficos de dispersão para as quatro variáveis quantitativas, distinguindo as espécies.

b) Calcule e represente graficamente a matriz de correlações das variáveis quantitativas.

c) Construa boxplots de `Petal.Length` por espécie, sobrepondo os valores individuais.

d) Ajuste uma reta de regressão de `Petal.Length` sobre `Petal.Width` para cada espécie e represente as três retas num único gráfico.

e) Compare visualmente os declives das retas e discuta as diferenças observadas.

f) Produza uma figura final utilizando `ggplot2`, com título, legenda, unidades e tema adequados a um relatório científico.

Exercício 8 — Regressão linear e diagnóstico

Considere novamente `mtcars`.

a) Ajuste os modelos

$$M_1: \quad mpg = \beta_0 + \beta_1 wt + \varepsilon$$
$$M_2: \quad mpg = \beta_0 + \beta_1 wt + \beta_2 hp + \varepsilon$$

b) Compare os modelos através de R^2, R^2_{ajustado}, AIC e BIC.

c) Interprete os coeficientes estimados e respetivos erros-padrão.

d) Represente os resíduos em função dos valores ajustados e construa um gráfico Q-Q.

e) Identifique potenciais observações influentes através da distância de Cook.

f) Construa intervalos de confiança para os coeficientes de regressão.

g) Para três automóveis hipotéticos, com características escolhidas dentro dos intervalos observados na amostra, obtenha previsões pontuais e intervalos de previsão a 95%.

UNIVERSIDADE ABERTA www.uab.pt

h) Discuta as limitações da utilização de modelos lineares neste conjunto de dados.

Grupo IV — Aplicações estatísticas com dados reais

Exercício 9 — Análise exploratória de dados biomédicos

Instale o package `ISwR` e considere as bases de dados `vitcap2`, `tlc` e `secher`, utilizadas na atividade original.

Para cada base de dados:

a) Identifique as variáveis, as respetivas escalas de medida e a dimensão da amostra.

b) Realize uma análise exploratória, incluindo medidas de localização, dispersão e representações gráficas adequadas.

c) Identifique possíveis observações atípicas e avalie a sua influência nas estatísticas descritivas.

d) Estude as associações entre as variáveis quantitativas, justificando a escolha das medidas utilizadas.

e) Formule uma questão estatística relevante para cada conjunto de dados e proponha uma metodologia para a investigar.

f) Desenvolva uma análise mais aprofundada para uma das bases, utilizando um modelo estatístico apropriado.

g) Apresente as conclusões, distinguindo resultados observados, hipóteses de modelação e limitações da análise.

Exercício 10 — Mini-projeto de programação estatística

Pretende-se desenvolver uma função em R que permita comparar dois estimadores da média populacional: a média amostral e a média aparada a 10%.

Considere amostras aleatórias independentes provenientes de uma distribuição normal padrão.

UNIVERSIDADE ABERTA www.uab.pt

a) Desenvolva uma função que, para uma dimensão amostral *n*, gere uma amostra e calcule os dois estimadores.

b) Generalize a função para realizar B repetições independentes da experiência.

c) Considere n=20,50,100 e B=1000. Estime, para cada estimador, o viés, a variância e o erro quadrático médio.

d) Repita a experiência utilizando uma distribuição t de Student com 3 graus de liberdade, centrada em zero.

e) Compare graficamente as distribuições empíricas dos estimadores.

f) Investigue o efeito da dimensão amostral no erro quadrático médio.

g) Garanta a reprodutibilidade dos resultados através de `set.seed()`.

h) Elabore uma conclusão fundamentada sobre o comportamento dos dois estimadores perante distribuições com diferentes características.

Orientações para a realização

A atividade deverá ser desenvolvida preferencialmente em RStudio, utilizando R base e, quando indicado, packages adicionais.

Recomenda-se que os estudantes apresentem um único documento em R Markdown, contendo código, resultados, gráficos e comentários interpretativos. O código deverá ser executável de forma sequencial, sem dependência de objetos previamente criados na sessão de trabalho.

A utilização de ferramentas de inteligência artificial pode constituir um apoio à aprendizagem, mas os estudantes deverão ser capazes de explicar o funcionamento do código e justificar as opções metodológicas adotadas.

UNIVERSIDAD ABIERTA www.uab.pt