Estatistica I – Actividade Formativa I

V.1

+ Diogo Marques +

1. Uma empresa pretende conhecer a opinião dos estudantes sobre a qualidade do ensino na universidade.

Após consultar uma amostra de estudantes, um investigador afirma: "A satisfação dos estudantes é de 80%". Outro investigador afrma: "Com 95% de coniança, a satisfação dos estudantes situa-se entre 75% e 85%".

(a) Que diferença existe entre as duas formas de apresentar os resultados?

1.ª afirmação: "A satisfação dos estudantes é de 80%."

É uma estimativa pontual: apresenta um único valor como estimativa do parâmetro populacional que é a verdadeira proporção de satisfação. Não indica incerteza nem precisão da estimativa.

2.ª afirmação: "Com 95% de confiança, a satisfação situa-se entre 75% e 85%." É uma estimativa intervalar dado num intervalo de confiança a 95%. Reconhece a incerteza da amostragem e

fornece um intervalo de valores plausíveis para o parâmetro, com um nível de confiança associado.

(b) Identifique o estimador utilizado e a estimativa obtida.

Estimador: a proporção amostral de estudantes satisfeitos, denotada por $\hat{p}$.

$$\hat{p}=\frac{n.^o \, de\ estudantes\ satisfeitos\ na\ amostra}{n.^o \, total\ de\ estudantes\ satisfeitos\ na\ amostra}$$

Estimativa: $\hat{p}=0,80$

Para construir o intervalo a 95% de confiança, usa-se a fórmula:

$$\hat{p} \pm z_{\alpha}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

Estimativa pontual $\hat{p}=0.80$

Nível de confiança: $1-\alpha=0,95$, logo $\alpha=0,05$

O intervalo de confiança é bilateral, logo:

$$Limite\ Inferior=\frac{\alpha}{2}=0,025 \quad \text{e} \quad limite\ superior=1-\alpha=0,975$$

Queremos um intervalo bilateral a 95%, usando a tabela da distribuição normal, temos:

$$P(z_{\alpha/2}\leq Z\leq z_{1-\alpha/2})=0,95\,;Z\sim(0,1)$$

Cauda inferior: $z_{0,025} \approx -1,96$

Cauda superior: $z_{0,975} \approx +1,96$

Para encontrar n usamos o intervalo [0,75;0,85] junto com a fórmula $\hat{p} \pm z_{\alpha}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$ para encontrar a margem de erro ME. Ou seja:

$ME \pm z_{\alpha}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

$ME = \frac{0,85-0,75}{2} = 0,05$

e de seguida resolvemos para encontrar n:

$0,05 = 1,96\sqrt{\frac{0,80\,x\,0,20}{n}}$ e resolvendo a expressão obtemos.

$n \approx \frac{0,16}{0,0006508} \approx 245,8 \approx 246$

Agora podemos contruir o intervalo com $n = 246$

O erro padrão SE = $\sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = \sqrt{\frac{0,16}{246}} \approx 0,02550$ que demos verificar dado que o intervalo é dado por $\hat{p} \pm ME = 0,80 \pm 0,05$

Assim verificamos que $IC_{95\%}(p) = [0,75;0,85]$ que corresponde exactamente a 75-85% como indicado.

(c) Se fosse selecionada uma amostra diferente, os resultados poderiam mudar? Justifique.

Sim, os resultados poderiam mudar. Cada amostra aleatória produz valores diferentes da proporção amostral p̂ (variabilidade amostral). O estimador p̂ é uma variável aleatória – a sua realização depende dos elementos selecionados. Tanto a

estimativa pontual como o intervalo de confiança variariam de amostra para amostra. O intervalo de confiança a 95% garante apenas que, em 95% das amostras possíveis, o intervalo construído contém o verdadeiro parâmetro populacional.

2. Pretende-se estimar o valor médio populacional μ de uma variável X,a partir de uma amostra aleatória de n observações independentes e identicamente distribuidas i.i.d. (X_1, X_2, …,X_n). Dê um exemplo de um estimador enviesado T_n que satisfaça $\lim_{n\to\infty} VAR(T_n)=0.$

Procuramos um estimador T_n para o parâmetro populacional média μ que cumpra duas condições:

1. ser enviesado, ou seja: $E[T_n]\neq\mu$ para n finito.

2. tenha variância assimptotica nula: $\lim_{n\to\infty} VAR(T_n)=0.$

Para resolver este problema, partimos da média amostral dada por $\bar{X}_n=\frac{1}{n}\sum_{i=1}^{n} X_i$, e a sua variância $VAR(\bar{X}_n)=\frac{\sigma^2}{n}$ que tende para 0 à medida que n→∞.

Para criar o estimador, multiplicamo-lo por uma constante $c\neq 1$. Temos:

$T_n=c\,\bar{X}_n$

E verificando o valor esperado $E[T_n]=E[c\,\bar{X}_n]=c\,E[\bar{X}_n]=c\,\mu$

Como $c\neq 1$, $E[T_n]\neq n$, logo o estimador é enviesado.

Vamos verificar a variância do estimador T_n:

$$VAR(T_n)=VAR(c\,\bar{X}_n)=c^2 VAR(\bar{X}_n)=c^2\frac{\sigma^2}{n}$$

e calculamos o limite da variância quando $n\to\infty$

$$\lim_{n\to\infty} VAR(T_n)=\lim_{n\to\infty}(c^2\frac{\sigma^2}{n})=c^2\sigma^2\lim_{n\to\infty}\frac{1}{n}=0$$

A condição é satisfeita quando σ^2 é finito.

3. Indique justificando o valor lógico das seguintes afirmações:

(a)Um estimador não-envieasado T_n é necessariamente consistente em média quadrática.

Falso.

Para que um estimados T_n seja consistente em média quadrática, é necessário que o seu erro quadrático médio tenda para zero quando $n\to\infty$:

$$\lim_{n\to\infty} EQM(T_n)=\lim_{n\to\infty}[VAR(T_n)+[BIAS(T_n)]^2]=0$$

Se o estimador não é enviesado, o seu viés é zero, assim o EQM reduz-se à variância:

$$EQM(T_n)=VAR(T_n)$$

Para ser consistente em MQ a variância tem de tender para zero:

$\lim_{n\to\infty} VAR(T_n)=0$, mas não ser enviesado não significa que a variância tende para zero esteja sempre garantida. Por exemplo:

uma amostra aleatória i.i.d.$(X_1, X_2, \ldots, X_n)$ de uma população com média μ e variância μ^2 finita. Se definirmos o estimador $T_n = X_1$ (usando apenas a primeira observação da amostra para estimar a média):

1. É nao-enviesado? Sim porque $E[T_n] = E[X_1] = \mu$

2. É consistente em MQ? Não porque $VAR(T_n) = VAR(X_1) = \sigma^2$

O limite da variância quando $n \to \infty$ é σ^2, logo $\lim_{n \to \infty} EQM(T_n) = \sigma^2 \neq 0$

Ou seja, um estimador não enviesado pode não ser consistente em média quadrática.

(b)Um estimador consistente é necessariamente centrado.

Falso.

Um estimador consistente não precisa ser centrado.

A consistência exige que o estimador convirja para o verdadeiro valor do parâmetro à medida que o tamanho da amostra tende para infinito:

$\lim_{n \to \infty} P(|T_n - \mu|) < \epsilon = 1, \forall \epsilon > 0$

A consistência é uma propriedade assimptótica.

A não enviesabilidade, ou seja se o estimador é centrado, é uma propriedade de amostra finita para qualquer n.

Um estimador pode ser enviesado para qualquer tamanho de amostra finito n, logo não é centrado. Mas à medida que n cresce, o viés

pode desaparecer e a variância diminuir o que o torna consistente.

A condição suficiente para consistência é que

$\lim_{n\to\infty} EQM(T_n)=0$, o que permite que o viés seja diferente de zero para n finito, desde que tenda para zero no limite.

4. Considere uma variável aleatória X com a distribuição de Poisson com uma média igual a λ. Pretende-se estimar λ a partir de uma amostra com n observações independentes $(x_1, x_2, \ldots, x_n)$. Mostre que a estimativa da máxima verosimilhança para o parâmetro λ é dada pela média amostral, $\lambda = \frac{\sum_{i=1}^{n} x_i}{n}$

Para Para mostrar que o MLE do parâmetro de Poisson é a média amostral λ, usamos os seguintes passos:

1. Definimos a função de probabilidade PMF:

Para uma variável aleatória X que segue uma distribuição de Poisson com a média λ, a probabilidade de observar um valor específico x é dada por:

$$P(X=x)=\frac{e^{-\lambda}\lambda^{x}}{x!}; x=0,1,2\ldots$$

2. Construimos a função de verosimilhança

Dada uma amostra de n observações independentes $(x_1, x_2, \ldots, x_n)$, a função de verosimilhança $L(\lambda)$ é a probabilidade conjunta de

observar esta amostra específica. Como as observações são independentes, é o produto das probabilidades individuais:

$$L(\lambda)=\prod_{i=1}^{n} P(X=x_i)=\frac{\prod_{i=1}^{n} e^{-\lambda}\lambda^{x_i}}{x_i!}$$

Simplificando, temos:

$$L(\lambda)=\frac{e^{-\lambda}\lambda^{x_1}}{x_1!}\cdot\frac{e^{-\lambda}\lambda^{x_2}}{x_2!}\dots\frac{e^{-\lambda}\lambda^{x_n}}{x_n!}$$

$$L(\lambda)=\frac{e^{-n\lambda}\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!}$$

3. Construir a função de log-verosimilhança

É mais fácil maximizar o logaritmo natural da função de verosimilhança, designado por log-verosimilhança e denotado por $\ell(\lambda)$. Como o logaritmo é uma função estritamente crescente, maximizar $\ell(\lambda)$ é equivalente a maximizar $L(\lambda)$.

$$\ell(\lambda)=\ln(L(\lambda))=\ln\left(\frac{e^{-n\lambda}\lambda^{\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n} x_i!}\right)$$

Utilizando as propriedades dos lorgaritmos $\ln(ab)=\ln(a)+\ln(b)$ e $\ln(a/b)=\ln(a)-\ln(b)$ temos:

$$\ell(\lambda)=\ln(e^{-n\lambda})+\ln(\lambda^{\sum x_i})-\ln\left(\prod_{i=1}^{n} x_i!\right)$$

$$\ell(\lambda) = -n\lambda + \left(\sum_{i=1}^{n} x_i\right)\ln(\lambda) - \sum_{i=1}^{n}\ln(x_i!)$$

4. Encontrar o máximo

Para encontrar o valor de λ que maximiza a log-verosimilhança, calculamos a derivada de ℓ(λ) em ordem a λ e igualamos a zero.

$$\frac{d\ell(\lambda)}{d\lambda} = \frac{d}{d\lambda}\left[-n\lambda + \left(\sum_{i=1}^{n} x_i\right)\ln(\lambda) - \sum_{i=1}^{n}\ln(x_i!)\right]$$

$$\frac{d\ell(\lambda)}{d\lambda} = -n + \left(\sum_{i=1}^{n} x_i\right)\frac{1}{\lambda} - 0$$

$$-n + \frac{\left(\sum_{i=1}^{n} x_i\right)}{\lambda} = 0$$

$$\frac{\left(\sum_{i=1}^{n} x_i\right)}{\lambda} = n$$

$$\lambda = \frac{\left(\sum_{i=1}^{n} x_i\right)}{n}$$

E para confirmar que se trata de um maximo se fizermos a segunda derivada obtemos:

$$\frac{d^2\ell(\lambda)}{d\lambda^2} = \frac{-\left(\sum_{i=1}^{n} x_i\right)}{\lambda^2}$$

Como todos os $x_i \geq 0$ e $\lambda > 0$, a a segunda derivada é negativa, confirma que este ponto crítico é um máximo.

O MLE para λ denotado por $\hat{\lambda}$ é dado por:

$\hat{\lambda} = \frac{\sum_{i=1}^{n} x_i}{n}$ que é a média amostral.

5. Assuma que o número de horas de estudo semanais dos estudantes de uma escola segue uma distribuição normal. Sabe-se que, independentemente do valor médio de horas de estudo dos estudantes, a dispersão em relação a esse valor médio costuma resultar num desvio-padrão de 30 minutos. Com o objectivo de estimar o valor médio de horas de estudo semanais dos estudantes da escola, decidiu-se recolher uma amostra aleatória de 100 alunos.

(a) Recolheu-se uma amostra nas condições especificadas e observou-se $\bar{x} = 8$. Determine um intervalo de confiança a 99% para o número médio de horas de estudo semanais dos alunos.

Como a população é normalmente distribuida, e conhecemos o desvio padrão populacional, usamos a distribuição Z.

Nivel de confiança: $1 - \alpha = 0{,}99 \Rightarrow \alpha = 0{,}01 \Rightarrow \alpha/2 = 0{,}005$

Valor Crítico: $z_{0{,}005} = 2{,}576$

$IC = \bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

$SE: \frac{\sigma}{\sqrt{n}} = \frac{0,5}{\sqrt{100}} = \frac{0,5}{10} = 0,05\, horas$

$ME: E = 2,576\, x\, 0,05 = 0,1288\, horas$

$IC = 8 \pm 0,1288$

O intervalo de confiança a 99% é]7,8712; 8,1288[

(b) Qual é o erro de estimação do intervalo anterior? Se a média amostral observada tivesse sido outra, o erro de estimação seria diferente? Justifique.

O Erro de estimação é metade da amplitude to intervalo de confiança.

$E = \frac{z_{\alpha/2} \cdot \sigma}{\sqrt{n}} = 2,576 \cdot 0,05 = 0,1288$ horas ou 7,728 minutos

Se $\bar{x}$ mudasse seria diferente? Nops. Apenas depende do nivel de confiança (z), do desvio-padrão populacional (σ) e do tamanho amostral (n). A média amostral $(\bar{x})$ determina o centro do intervalo mas não a sua amplitude (o erro). Portanto manter-se-ia constante.

(c) Se a dimensão da amostra escolhida fosse 200, o erro de estimação diminuiria ou aumentaria? Apresente a resposta sem recorrer a cálculos.

Iria diminuir. A formula da estimação do erro tem no denominador $\left(E=\frac{z\cdot\sigma}{\sqrt{n}}\right)$. à medida que o tamanho amostral aumenta, o denominador torna-se maior o que torna o erro mais pequeno.

(d) Suponha que pretende apresentar uma estimativa intervalar com 99% de confiança que não apresente um erro de estimação superior a 6 minutos. Qual deve ser a dimensão da amostra a recolher?

Erro pretendido (E): 6 minutos = 0,1 horas.

Nível de Confiança: 99% ⇒ z = 2,576

σ = 0,5 horas

$$n=\left(\frac{z\cdot\sigma}{E}\right)^2$$

$$n=\left(\frac{2{,}576\cdot 0{,}5}{0{,}1}\right)^2$$

$$n=(12{,}88)^2\approx 165.89$$

$n=166$ alunos

(e) Suponha agora que a única amostra a que tem acesso é a amostra mencionada na alínea (a). Que nível de con#ança deve escolher para poder apresentar novamente uma estimativa intervalar que apresente um erro de estimação máximo de 6 minutos?

Erro (E): 6 minutos = 0,1 horas

Tamanho Amostral (n): 100

$\sigma = 0{,}5$

$$E = z \cdot \frac{\sigma}{\sqrt{n}} \Rightarrow 0{,}1 = z \cdot \frac{0{,}5}{10}$$

$$0{,}1 = z \cdot 0{,}05$$

$$z = \frac{0{,}1}{0{,}05} = 2{,}0$$

Para encontrar a probabilidade para $z = 2$ usamos a tabela da distribuição normal.

$$P(Z < 2) = 0{,}9772$$

Para um intervalo bi-partido, o nível de confiança é:

CL = 2 x 0,9772 – 1 = 0,9544

O nivel de confiança (CL) deve ser: 95,44%

(f) Novamente com recurso à amostra mencionada na alínea (a), faça uma estimativa pontual para o número médio de horas de estudo semanais dos alunos.

A estimativa pontual é apenas a média amostral

$\hat{\mu} = \bar{x} = 8\,horas$

Código Python

```
import numpy as np
from scipy import stats


n, xbar, sigma = 100, 8, 0.5  # sigma em horas
z_99 = stats.norm.ppf(0.995)           # 2.5758


# (a) IC 99%
E = z_99 * sigma / np.sqrt(n)
print(f"IC 99%: ({xbar - E:.4f}, {xbar + E:.4f})")


# (d) n mínimo para E <= 6 min = 0.1 h
E_max = 6/60
n_min = np.ceil((z_99 * sigma / E_max)**2)
print(f"n mínimo = {int(n_min)}")


# (e) Nível de confiança
z_e = E_max * np.sqrt(n) / sigma      # = 2.0
conf = 2 * stats.norm.cdf(z_e) - 1
print(f"Confiança = {conf*100:.2f}%")
```

6. Foram recolhidas as idades de uma amostra de 20 alunos, conforme a tabela seguinte.

21 22 22 23 27 31 34 35 36 36 38 38 42 42 42 47 48 52 58 67
Justificando a escolha, apresente uma estimativa pontual e por intervalo de confiança a 95% e a 99% para o valor médio e para o desvio padrão populacionais.

$\bar{x}$ = 38.05 anos

s = 12.3437 anos (desvio-padrão amostral)

n = 20

Como σ é desconhecida, usa-se a distribuição t de Student com n−1 = 19 graus de liberdade para a média, e a distribuição χ^2 com 19 g.l. para o desvio-padrão.

Estimativa Pontual

Média: $\bar{x}$ = 38.05 anos

Desvio-padrão: s = 12.34 anos

Intervalo de Confiança para a Média (t-Student, 19 g.l.)

$t_{0,025}$ (df=19) = 2.0930 → IC 95%: (38.05 ± 2.0930 × 12.3437/√20)

IC 95% para μ: (32.27, 43.83) anos

$t_{0,005}$ (df=19) = 2.8609 → IC 99%: (38.05 ± 2.8609 × 12.3437/√20)

IC 99% para μ: (30.15, 45.95) anos

Intervalo de Confiança para o Desvio-Padrão (χ², 19 g.l.)

IC 95%: $\chi^2_{0,025}$=8.9065, $\chi^2_{0,975}$=32.8523

IC para σ: (√(19×152.37/32.8523), √(19×152.37/8.9065))

IC 95% para σ: (9.39, 18.03) anos

IC 99%: $\chi^2_{0,005}$=6.8440, $\chi^2_{0,995}$=38.5823

IC 99% para σ: (8.66, 20.57) anos

Código Python

```
import numpy as np
from scipy import stats


ages = [21,22,22,23,27,31,34,35,36,36,38,38,42,42,42,47,48,52,58,67]
n, xbar, s = len(ages), np.mean(ages), np.std(ages, ddof=1)
s2 = s**2


# IC para a média (t-Student)
for conf, alpha in [(0.95, 0.05), (0.99, 0.01)]:
    t = stats.t.ppf(1-alpha/2, df=n-1)
    E = t * s / np.sqrt(n)
    print(f"IC {conf*100:.0f}% μ: ({xbar-E:.2f}, {xbar+E:.2f})")


# IC para o desvio-padrão (chi-quadrado)
for conf, alpha in [(0.95, 0.05), (0.99, 0.01)]:
    c_lo = stats.chi2.ppf(alpha/2,   df=n-1)
    c_hi = stats.chi2.ppf(1-alpha/2, df=n-1)
    lo = np.sqrt((n-1)*s2 / c_hi)
```

```
    hi = np.sqrt((n-1)*s2 / c_lo)
    print(f"IC {conf*100:.0f}% σ: ({lo:.2f}, {hi:.2f})")
```

7. Com o objectivo de estudar as emissões de monóxido de carbono (g/km) de um certo tipo de veículo a circular a uma velocidade de 90 km/h, foi recolhida a seguinte amostra.

18,3; 18,1; 18,3; 18,4; 18,2; 17,8; 17,9; 18,1;

Assuma que a população é normalmente distribuída.

(a) Apresente uma estimativa pontual para o valor médio das emissões de monóxido de carbono do dito tipo de veículo (a 90 km/h).

n = 8;

Estimativa Pontual:

$$\bar{x} = \frac{18{,}3+18{,}1+18{,}3+18{,}4+18{,}2+17{,}8+17{,}9+18{,}1}{8} = 145{,}1$$

$$\bar{x} = \frac{145{,}1}{8} = 18{,}1375\, g/km$$

(b) Apresente uma estimativa intervalar com um grau de confiança de 95% para o valor médio das emissões de monóxido de carbono do dito tipo de veículo (a 90 km/h).

Como a população é normal e σ é desconhecido, usamos a distribuição t de Student com n−1=7 graus de liberdade.

Datapoint	Datapoint – Avg	← Squared dif.
18,3000	0,1625	0,0264
18,1000	-0,0375	0,0014
18,3000	0,1625	0,0264
18,4000	0,2625	0,0689
18,2000	0,0625	0,0039
17,8000	-0,3375	0,1139
17,9000	-0,2375	0,0564
18,1000	-0,0375	0,0014

Average	SS
18,1375	0,2988
s^2	SE
0,0427	0,0730
s	
0,2066	

Figura 1 – Cálculos excel de suporte

Valor crítico:

$t_{0,025\,;\,7} = 2{,}365$

Margem de erro:

ME = 2,365 x 0,07304 = 0,1727

Intervalo de confiança a 95%:

18,1375 ± 0,1727 = (17,9648;18,3102)

IC 95%: (17,96;18,31) g/km

(c) Suponha que, usando a mesma amostra, se pretende reduzir a amplitude do intervalo de confiança em 10%. Apresente um novo intervalo de confiança para esse efeito, indicando a respetiva confiança

A amplitude actual é 2E = 2 × 0.1727 = 0.3454.

Pretende-se uma nova amplitude = 0.9 × 0.3454 = 0.3109, ou seja, novo E = 0.1554.

Mantendo n e s iguais, o único parâmetro que pode mudar é t:

t_novo = 0.9 × $t_{0,025}$(df=7) = 0.9 × 2.3646 = 2.1282

P($T_7 \leq 2.1282$) ⇒ confiança = 92.91%

Novo IC (92.91%): (17.9821, 18.2929) g/km

8. Em determinada sondagem à boca das urnas, foram inquiridos mil eleitores (do universo de 3.4 milhões que votaram nesse dia). Chegou-se à conclusão que 53% dos inquiridos afirmaram votar no candidato A. Conclua se pode afirmar, com 95% de confiança, que o candidato A terá maioria absoluta.

n = 1000 eleitores inquiridos; $\hat{p}$ = 0.53 (53% afirmaram votar no candidato A).

Questão: pode afirmar-se, com 95% de confiança, que o candidato A terá maioria absoluta (p > 0.50)?

$z_{0,025}$ = 1.9600

E = 1.9600 × √(0.53 × 0.47 / 1000) = 1.9600 × 0.01578 = 0.0309

IC 95%: (0.53 − 0.0309, 0.53 + 0.0309) = (0.4991, 0.5609)

O limite inferior do IC é 0.4991 < 0.50. O valor 0.50 está dentro do intervalo de confiança.

Conclusão: NÃO se pode afirmar, com 95% de confiança, que o candidato A terá maioria absoluta, pois o IC inclui valores abaixo de 50%.

Código Python

```
import numpy as np
from scipy import stats

n, phat = 1000, 0.53
z95 = stats.norm.ppf(0.975)
E = z95 * np.sqrt(phat * (1-phat) / n)
ci = (phat - E, phat + E)
print(f"IC 95%: ({ci[0]:.4f}, {ci[1]:.4f})")
print(f"Maioria absoluta garantida? {ci[0] > 0.5}")
```

9. A partir de uma sondagem à boca das urnas, uma empresa conseguiu apresentar um intervalo centrado com 95% de confiança para a proporção de votos “sim” num referendo para a regionalização.

Do gráfico: intervalo para SIM é (35.5%, 39.5%). Centro: $\hat{p}$ = 37.5%, semi-amplitude: E = 2.0%.

(a) Com n = 800, quantos votos "sim"?

Nº de votos sim = $\hat{p} \times n = 0.375 \times 800 = 300$ votos

300 votos "sim" na amostra (se n = 800)

(b) Verificar se n = 800 é confirmado pelo intervalo

IC 95% com n=800 e $\hat{p}=0.375$:

$E = 1.9600 \times \sqrt{(0.375 \times 0.625 / 800)} = 0.0335$

$IC = (0.375 - 0.0335, 0.375 + 0.0335) = (0.3415, 0.4085)$

O IC obtido com n = 800 é (34.15%, 40.85%), diferente do apresentado (35.5%, 39.5%). A hipótese n = 800 NÃO se confirma.

(c) Verdadeira dimensão da amostra

$E = z \times \sqrt{(\hat{p}(1-\hat{p})/n)} = 0.020$

$n = (z \times \sqrt{(\hat{p}(1-\hat{p}))} / E)^2 = (1.9600 \times \sqrt{(0.375 \times 0.625)} / 0.020)^2$

$n = (1.9600 \times 0.4841 / 0.020)^2 = 47.44^2 \approx 2250.85$

Verdadeira dimensão da amostra: n ≈ 2251 eleitores

(d) Comentário à afirmação sobre probabilidade

A afirmação "A probabilidade de a proporção de votos sim estar entre 35.5% e 39.5% é igual a 0.95" é incorrecta do ponto de vista frequentista.

A proporção populacional p é um parâmetro fixo desconhecido, não uma variável aleatória. A probabilidade de um valor fixo estar num intervalo fixo é 0 ou 1, não podemos saber qual. O nível de 95% refere-se ao processo de construção: se repetíssemos a amostragem e construíssemos o IC muitas vezes, 95% dos intervalos construídos conteriam o verdadeiro p.

Código Python

```
import numpy as np
from scipy import stats

phat = 0.375  # centro do intervalo observado
hw = 0.020    # semi-amplitude observada
z95 = stats.norm.ppf(0.975)

# (b) IC com n=800
n_800 = 800
E_800 = z95 * np.sqrt(phat*(1-phat)/n_800)
print(f"IC com n=800: ({phat-E_800:.4f}, {phat+E_800:.4f})")

# (c) Verdadeira dimensão
n_real = (z95 * np.sqrt(phat*(1-phat)) / hw)**2
print(f"n real = {n_real:.1f} => {int(np.ceil(n_real))}")
```

10.

(a) Amostras Emparelhadas — Estatística I vs. Computação Estatística I

Dados emparelhados (mesmo aluno nas duas UCs). Utiliza-se o teste para diferença de médias em amostras emparelhadas.

Diferenças d = EI − CEI: −1, −3, −3, +1, −3, −2, −1, −3

$\bar{d}$ = −1.875, s^d = 1.4577, n = 8

Distribuição: t com df = n−1 = 7

$t_{0,05}$(df=7) = 3.4995

E = 3.4995 × 1.4577/√8 = 1.8036

IC 99%: (−1.875 − 1.804, −1.875 + 1.804) = (−3.679, −0.071)

IC 99% para μ_{EI} − μ_{CEI}: (−3.68, −0.07)

O intervalo não contém o zero, logo rejeitamos a hipótese de igualdade de médias. Com 99% de confiança, as notas de Computação Estatística I são significativamente mais altas do que as de Estatística I.

(b) Amostras Independentes — Curso A vs. Curso B (variâncias iguais)

Assumindo igualdade de variâncias, usa-se a variância pooled e t com df = n_A + n_B − 2.

Curso A: n=10, $\bar{x_A}$=12.30, s_A=3.683

Curso B: n=8, $\bar{x_B}$=11.875, s_B=3.182

s^2_{pooled} = (9×3.683² + 7×3.182²) / 16 = (122.07 + 70.83)/16 = 12.056 => s_p = 3.473

df = 16, $t_{0,05}$(df=16) = 1.7459 (para 90% de confiança)

E = 1.7459 × 3.473 × √(1/10+1/8) = 1.7459 × 3.473 × 0.4743 = 2.876

IC 90%: (12.30−11.875 ± 2.876) = (0.425 ± 2.876) = (−2.451, 3.301)

IC 90% para $\mu_A - \mu_B$: (−2.45, 3.30)

O intervalo contém o zero: com 90% de confiança, não há evidência suficiente para afirmar que as médias dos dois cursos são diferentes.

(c) Justificação da diferente escolha entre (a) e (b)

Em (a) as medições são feitas no mesmo aluno (EI e CEI são do mesmo indivíduo), criando uma dependência natural entre as observações. Por isso usam-se amostras emparelhadas (diferenças), que eliminam a variabilidade inter-individual e aumentam o poder do teste.

Em (b) as amostras são de alunos diferentes e independentes nos dois cursos, não existindo correspondência entre eles. Aqui usa-se o método de duas amostras independentes.

Código Python

```
import numpy as np
from scipy import stats

# (a) Amostras emparelhadas
ei  = np.array([14,11,10,15,10,12,18,11])
cei = np.array([15,14,13,14,13,14,19,14])
d = ei - cei
n_a, dbar, sd = len(d), np.mean(d), np.std(d, ddof=1)
t99 = stats.t.ppf(0.995, df=n_a-1)
```

```
E_a = t99 * sd / np.sqrt(n_a)
print(f"IC 99% (emparelhado): ({dbar-E_a:.4f},
{dbar+E_a:.4f})")

# (b) Duas amostras independentes (variâncias iguais)
A = np.array([18,8,10,13,12,11,14,6,15,16])
B = np.array([15,10,12,8,8,17,13,12])
nA, nB = len(A), len(B)
xA, xB = np.mean(A), np.mean(B)
sA, sB = np.std(A,ddof=1), np.std(B,ddof=1)
sp2 = ((nA-1)*sA**2 + (nB-1)*sB**2) / (nA+nB-2)
sp  = np.sqrt(sp2)
df  = nA + nB - 2
t90 = stats.t.ppf(0.95, df=df)
E_b = t90 * sp * np.sqrt(1/nA + 1/nB)
diff = xA - xB
print(f"IC 90% (indep.): ({diff-E_b:.4f}, {diff+E_b:.4f})")
```