Actividade Formativa 2 — Resolução — Diogo Marques

Testes de Hipóteses para uma ou duas amostras

Exercício 1

(a) Intervalo de confiança vs. Teste de hipóteses

Um **intervalo de confiança** é uma estimativa intervalar que fornece um conjunto de valores plausíveis para um parâmetro populacional, com um dado grau de confiança $(1-\alpha)$. Um **teste de hipóteses** é um procedimento de decisão que permite verificar se os dados amostrais são compatíveis com uma hipótese sobre o parâmetro, com base num nível de significância α. Embora relacionados (um IC a $(1-\alpha)$ e um teste bilateral com significância α são equivalentes), os objetivos diferem: o IC estima, o teste decide.

(b) Testes paramétricos vs. não paramétricos

Os **testes paramétricos** assumem uma forma específica para a distribuição populacional (geralmente Normal) e formulam hipóteses sobre os seus parâmetros (ex.: μ, σ^2). Os **testes não paramétricos** não assumem uma distribuição particular para a população; são mais gerais e robustos, mas tipicamente menos potentes quando os pressupostos paramétricos se verificam.

Exercício 2 — Valor lógico das afirmações

(a) VERDADEIRO

A hipótese de interesse (que se quer demonstrar) deve ser colocada como hipótese alternativa H_1, pois o teste é desenhado para reunir evidência contra H_0. Rejeitar H_0 é a conclusão "forte"; não rejeitar é apenas falta de evidência contrária.

(b) VERDADEIRO

A região de rejeição para $\alpha = 1\%$ é um subconjunto da região de rejeição para $\alpha = 5\%$. Se a estatística de teste não cai na região de rejeição de 5%, então também não cai na de 1% (mais restrita). Equivalentemente, se o p-value é superior a 0,05, então é necessariamente superior a 0,01.

(c) FALSO

Num teste bilateral para a média com σ conhecido, a estatística de teste é:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$$

O p-value bilateral é $2P(Z > |z_{obs}|)$. Se a média amostral diminui (afastando-se mais de μ_0), $|z_{obs}|$ aumenta e o p-value **diminui**, não aumenta.

(d) VERDADEIRO

Num teste unilateral $H_1 : \mu_1 > \mu_2$ com significância α, a zona de rejeição ocupa α numa só cauda. No teste bilateral $H_1 : \mu_1 \neq \mu_2$ com significância 2α, cada cauda tem α, pelo que a cauda relevante (superior) coincide. As regiões de rejeição são idênticas e os dois testes são equivalentes.

(e) FALSO

Se a probabilidade de a média amostral exceder o valor crítico inferior é 99,7%, então a probabilidade de estar abaixo desse valor crítico é 0,3%. Esta é a probabilidade de erro tipo I **numa só cauda**. Como o teste é bilateral, o erro tipo I total é $\alpha = 2 \times 0{,}3\% = 0{,}6\%$, não 0,3%.

(f) FALSO

Embora os testes não paramétricos sejam mais gerais, os testes paramétricos são **mais potentes** quando os seus pressupostos se verificam. Usar um teste não paramétrico quando a normalidade se verifica desperdiça informação.

(g) VERDADEIRO

Quando se rejeita H_0, pode-se estar a cometer um **erro do tipo I** (rejeitar H_0 quando ela é verdadeira). A probabilidade desse erro é α.

(h) VERDADEIRO

A **potência** de um teste é $1-\beta$, onde β é a probabilidade do erro tipo II. As duas grandezas estão diretamente relacionadas: conhecendo uma determina-se imediatamente a outra. Uma maior potência corresponde a um menor erro tipo II, e vice-versa.

Exercício 3

Contexto: $X \sim N(\mu,\, \sigma = 0{,}5 \text{ h})$, $n = 100$, $\bar{x} = 8{,}4$ h. **Afirmação do representante:** $\mu \geq 8{,}5$ h/semana.

(a) Com $\alpha = 5\%$, a afirmação deve ser posta em causa?

$$H_0 : \mu \geq 8{,}5 \qquad H_1 : \mu < 8{,}5$$

$$Z_{obs} = \frac{8{,}4 - 8{,}5}{0{,}5/\sqrt{100}} = \frac{-0{,}1}{0{,}05} = -2{,}00$$

Valor crítico: $z_{0{,}05} = -1{,}645$. Como $-2{,}00 < -1{,}645$, **rejeita-se** H_0. A afirmação deve ser colocada em causa.

(b) Significância a partir da qual a afirmação é posta em causa

$$p\text{-value} = P(Z < -2{,}00) = \Phi(-2{,}00) \approx 0{,}0228$$

A afirmação deve ser colocada em causa para $\alpha > 2{,}28\%$.

(c) Valores de $\bar{x}$ que põem a afirmação em causa (para $n = 100$, $\alpha = 0{,}05$)

$$\bar{x} < 8{,}5 - 1{,}645 \times 0{,}05 = 8{,}4178$$

```
import numpy as np
from scipy import stats

mu0, sigma, n, x_bar = 8.5, 0.5, 100, 8.4
z_obs = (x_bar - mu0) / (sigma / np.sqrt(n))
print(f"Z_obs = {z_obs:.4f}")                          # -2.0000
```

```python
# (a)
z_crit = stats.norm.ppf(0.05)
print(f"z_crit = {z_crit:.4f}")                    # -1.6449
print(f"Reject H0: {z_obs < z_crit}")              # True

# (b)
p_value = stats.norm.cdf(z_obs)
print(f"p-value = {p_value:.4f}")                  # 0.0228

# (c)
x_crit = mu0 + z_crit * sigma / np.sqrt(n)
print(f"Reject when x_bar < {x_crit:.4f}")         # 8.4178
```

Exercício 4

Contexto: $n = 1000$, $\hat{p} = 0{,}53$.

(a) A partir de que nível de significância se conclui que o candidato A terá maioria absoluta?

$H_0 : p \leq 0{,}5 \quad$ vs. $\quad H_1 : p > 0{,}5$

$$Z_{obs} = \frac{0{,}53 - 0{,}5}{\sqrt{0{,}5 \times 0{,}5/1000}} = \frac{0{,}03}{0{,}01581} \approx 1{,}897$$

$$p\text{-value} = P(Z > 1{,}897) \approx 0{,}0289$$

Conclui-se maioria absoluta para $\alpha > 2{,}89\%$: pode-se concluir a 5% mas não a 1%.

(b) Comparação com o exercício 8 da AF1

$$IC_{95\%} = 0{,}53 \pm 1{,}96\sqrt{\frac{0{,}53 \times 0{,}47}{1000}} = [0{,}4991;\ 0{,}5609]$$

Como $0{,}5 \in [0{,}4991;\ 0{,}5609]$, não se pode afirmar com 95% de confiança que $p > 0{,}5$. Não há contradição: o IC bilateral corresponde a um teste bilateral (p-value $\approx 5{,}78\% > 5\%$), enquanto o teste unilateral rejeita H_0 a 5%.

```python
import numpy as np
from scipy import stats

p_hat, p0, n = 0.53, 0.5, 1000

# (a)
z_obs = (p_hat - p0) / np.sqrt(p0 * (1 - p0) / n)
print(f"Z_obs = {z_obs:.4f}")                      # 1.8974
p_value = 1 - stats.norm.cdf(z_obs)
print(f"p-value = {p_value:.4f}")                  # 0.0289

# (b)
z95 = stats.norm.ppf(0.975)
margin = z95 * np.sqrt(p_hat * (1 - p_hat) / n)
ci = [p_hat - margin, p_hat + margin]
```

```
print(f"IC 95%: [{ci[0]:.4f}, {ci[1]:.4f}]")          # [0.4991, 0.5609]
print(f"0.5 inside IC: {ci[0] <= 0.5 <= ci[1]}")       # True
```

Exercício 5

Contexto: $\mu_0 = 1000$ g, $\sigma = 100$ g (conhecido), $n = 9$, $\bar{x} = 967{,}3$ g.

(a) A partir de que nível de significância se considera que a máquina não está afinada?

$H_0 : \mu = 1000$ vs. $H_1 : \mu \neq 1000$

$$Z_{obs} = \frac{967{,}3 - 1000}{100/\sqrt{9}} = \frac{-32{,}7}{33{,}33} \approx -0{,}981$$

$$p\text{-value} = 2\Phi(-0{,}981) \approx 0{,}3266$$

A máquina é considerada não afinada para $\alpha > 32{,}66\%$. Para níveis habituais não se rejeita H_0.

(b) Com $\alpha = 5\%$, que tipo de erro se pode cometer?

Como **não se rejeita** H_0, o erro possível é o **erro do tipo II** (β).

(c) Valor de β para $\mu_1 = 980$ g

Valores críticos ($\alpha = 5\%$, bilateral):

$$\bar{x}_c^{inf} = 1000 - 1{,}96 \times \frac{100}{3} = 934{,}67 \qquad \bar{x}_c^{sup} = 1065{,}33$$

$$Z_1 = \frac{934{,}67 - 980}{33{,}33} \approx -1{,}360 \qquad Z_2 = \frac{1065{,}33 - 980}{33{,}33} \approx 2{,}560$$

$$\beta = \Phi(2{,}560) - \Phi(-1{,}360) \approx 0{,}9948 - 0{,}0869 = 0{,}908$$

```
import numpy as np
from scipy import stats

mu0, sigma, n, x_bar = 1000, 100, 9, 967.3

# (a)
z_obs = (x_bar - mu0) / (sigma / np.sqrt(n))
print(f"Z_obs = {z_obs:.4f}")                          # -0.9810
p_value = 2 * stats.norm.cdf(z_obs)
print(f"p-value = {p_value:.4f}")                      # 0.3266

# (c)
mu1 = 980
x_low  = mu0 - 1.96 * sigma / np.sqrt(n)
x_high = mu0 + 1.96 * sigma / np.sqrt(n)
print(f"Critical bounds: [{x_low:.2f}, {x_high:.2f}]") # [934.67, 1065.33]

z1 = (x_low  - mu1) / (sigma / np.sqrt(n))
```

```
z2 = (x_high - mu1) / (sigma / np.sqrt(n))
print(f"Z1 = {z1:.4f}, Z2 = {z2:.4f}")                  # -1.3600, 2.5600
beta = stats.norm.cdf(z2) - stats.norm.cdf(z1)
print(f"beta = {beta:.4f}")                              # 0.9078
```

Exercício 6

Contexto: Idades de 20 alunos da UAb. Testar normalidade com $\alpha = 5\%$.

Dados: 21, 22, 22, 23, 27, 31, 34, 35, 36, 36, 38, 38, 42, 42, 42, 47, 48, 52, 58, 67

Usa-se o **teste de Shapiro-Wilk** (adequado para n pequeno).

$$H_0 : \text{a população é Normal} \qquad H_1 : \text{a população não é Normal}$$

$W \approx 0{,}952$, p-value $\approx 0{,}40 > 0{,}05$. **Não se rejeita** H_0: o pressuposto de normalidade **não foi violado**.

```
import numpy as np
from scipy import stats

ages = [21,22,22,23,27,31,34,35,36,36,38,38,42,42,42,47,48,52,58,67]
print(f"mean = {np.mean(ages):.4f}")                     # 38.0500
print(f"s    = {np.std(ages, ddof=1):.4f}")              # 12.3437
print(f"s^2  = {np.var(ages, ddof=1):.4f}")              # 152.3658

W, p = stats.shapiro(ages)
print(f"W = {W:.4f}, p-value = {p:.4f}")                 # W=0.9521, p=0.4004
print(f"Reject normality at 5%: {p < 0.05}")             # False
```

Exercício 7

(a) Diferença entre notas de Estatística I e Computação Estatística I

Dados (amostras emparelhadas, $n = 8$):

Aluno	Est. I	Comp. Est. I	d_i
1	14	15	-1
2	11	14	-3
3	10	13	-3
4	15	14	+1
5	10	13	-3
6	12	14	-2
7	18	19	-1
8	11	14	-3

$$\bar{d} = -1{,}875 \qquad s_d \approx 1{,}458$$

$H_0 : \mu_d = 0$ vs. $H_1 : \mu_d \neq 0$, $\alpha = 1\%$

$$t_{obs} = \frac{-1{,}875}{1{,}458/\sqrt{8}} \approx -3{,}638$$

Valor crítico: $t_{7;\,0{,}005} = \pm 3{,}499$. Como $|t_{obs}| = 3{,}638 > 3{,}499$, **rejeita-se** H_0. A diferença é estatisticamente significativa.

```
import numpy as np
from scipy import stats

est1  = np.array([14, 11, 10, 15, 10, 12, 18, 11])
comp1 = np.array([15, 14, 13, 14, 13, 14, 19, 14])
d = est1 - comp1

d_bar = np.mean(d)
s_d   = np.std(d, ddof=1)
n     = len(d)
print(f"d_bar = {d_bar:.4f}")                          # -1.8750
print(f"s_d   = {s_d:.4f}")                            # 1.4577

t_obs  = d_bar / (s_d / np.sqrt(n))
t_crit = stats.t.ppf(0.995, df=n-1)
p_val  = 2 * stats.t.cdf(t_obs, df=n-1)
print(f"t_obs  = {t_obs:.4f}")                         # -3.6380
print(f"t_crit = ±{t_crit:.4f}")                       # ±3.4995
print(f"p-value = {p_val:.4f}")                        # 0.0083
print(f"Reject H0 at 1%: {abs(t_obs) > t_crit}")       # True

# Scipy shortcut
t_sc, p_sc = stats.ttest_rel(est1, comp1)
print(f"Scipy: t={t_sc:.4f}, p={p_sc:.4f}")
```

(b) Notas de Estatística I no Curso A vs. Curso B

Dados: - Curso A ($n_A = 10$): 18, 8, 10, 13, 12, 11, 14, 6, 15, 16 - Curso B ($n_B = 8$): 15, 10, 12, 8, 8, 17, 13, 12

$$\bar{x}_A = 12{,}3 \qquad \bar{x}_B = 11{,}875 \qquad s_p^2 \approx 12{,}061$$

$H_0 : \mu_A \leq \mu_B \quad$ vs. $\quad H_1 : \mu_A > \mu_B$

$$t_{obs} = \frac{12{,}3 - 11{,}875}{3{,}473 \times \sqrt{1/10 + 1/8}} \approx 0{,}258 \qquad \nu = 16$$

p-value $\approx 0{,}400$. Não há evidência de que as notas do Curso A sejam mais elevadas (apenas para $\alpha > 40\%$).

```
import numpy as np
from scipy import stats

A = np.array([18, 8, 10, 13, 12, 11, 14, 6, 15, 16])
B = np.array([15, 10, 12, 8, 8, 17, 13, 12])
nA, nB = len(A), len(B)

xA, xB   = np.mean(A), np.mean(B)
sA2, sB2 = np.var(A, ddof=1), np.var(B, ddof=1)
```

```
print(f"xA={xA:.4f}, xB={xB:.4f}")                    # 12.3, 11.875
print(f"sA^2={sA2:.4f}, sB^2={sB2:.4f}")              # 13.5667, 10.1250

sp2 = ((nA-1)*sA2 + (nB-1)*sB2) / (nA + nB - 2)
sp  = np.sqrt(sp2)
print(f"sp^2 = {sp2:.4f}, sp = {sp:.4f}")             # 12.0609, 3.4729

t_obs = (xA - xB) / (sp * np.sqrt(1/nA + 1/nB))
df    = nA + nB - 2
p_val = 1 - stats.t.cdf(t_obs, df)
print(f"t_obs = {t_obs:.4f}")                          # 0.2580
print(f"p-value (right-tailed) = {p_val:.4f}")         # 0.3999

# Scipy shortcut
t_sc, p_sc = stats.ttest_ind(A, B, equal_var=True, alternative='greater')
print(f"Scipy: t={t_sc:.4f}, p={p_sc:.4f}")
```

Exercício 8

Contexto: 10 carros, medições emparelhadas (sem aditivo / com aditivo).

$$\bar{d} = 0{,}205 \qquad s_d \approx 0{,}1885$$

$H_0 : \mu_d \leq 0$ vs. $H_1 : \mu_d > 0$, $\alpha = 1\%$

$$t_{obs} = \frac{0{,}205}{0{,}1885/\sqrt{10}} \approx 3{,}439$$

Valor crítico: $t_{9;\,0{,}01} = 2{,}821$. Como $3{,}439 > 2{,}821$, **rejeita-se** H_0. Com 1% de significância, o aditivo reduz significativamente o consumo de combustível.

```
import numpy as np
from scipy import stats

sem = np.array([8.08, 6.85, 8.46, 7.80, 7.06, 10.53, 8.47, 6.79, 7.11, 9.30])
com = np.array([7.71, 6.72, 8.42, 7.76, 6.70, 10.34, 8.42, 6.21, 6.83, 9.29])
d = sem - com

d_bar = np.mean(d)
s_d   = np.std(d, ddof=1)
n     = len(d)
print(f"d_bar = {d_bar:.4f}")                          # 0.2050
print(f"s_d   = {s_d:.4f}")                            # 0.1885

t_obs  = d_bar / (s_d / np.sqrt(n))
t_crit = stats.t.ppf(0.99, df=n-1)
p_val  = 1 - stats.t.cdf(t_obs, df=n-1)
print(f"t_obs  = {t_obs:.4f}")                         # 3.4388
print(f"t_crit = {t_crit:.4f}")                        # 2.8214
print(f"p-value = {p_val:.4f}")                        # 0.0037
print(f"Reject H0 at 1%: {t_obs > t_crit}")            # True
```

```python
# Scipy shortcut
t_sc, p_sc = stats.ttest_rel(sem, com, alternative='greater')
print(f"Scipy: t={t_sc:.4f}, p={p_sc:.4f}")
```

Exercício 9

Contexto: Amostra de 36 pessoas; testar se a presença de doença depende do género.

Tabela de contingência observada:

	Masculino	Feminino	Total
Doente	15	3	18
Saudável	14	4	18
Total	**29**	**7**	**36**

H_0: a doença é independente do género.

Frequências esperadas: $E_{12} = E_{22} = 3{,}5 < 5 \rightarrow$ recomenda-se o **teste exato de Fisher**.

$$\chi^2 = 0{,}178 \ll \chi^2_{1;\,0{,}05} = 3{,}841 \qquad p\text{-value} \approx 0{,}674$$

Não se rejeita H_0: não há evidência de que a doença dependa do género.

```python
import numpy as np
from scipy import stats

obs = np.array([[15, 3],
                [14, 4]])

# Chi-squared test
chi2, p_chi2, dof, expected = stats.chi2_contingency(obs, correction=False)
print(f"Expected:\n{expected}")                          # [[14.5, 3.5], [14.5, 3.5]]
print(f"Chi2 = {chi2:.4f}")                              # 0.1773
print(f"p-value = {p_chi2:.4f}")                         # 0.6737
print(f"Chi2 critical (5%) = {stats.chi2.ppf(0.95,1):.4f}")  # 3.8415
print(f"Reject H0 at 5%: {chi2 > stats.chi2.ppf(0.95, 1)}")  # False

# Fisher's exact test (recommended since expected values < 5)
_, p_fisher = stats.fisher_exact(obs)
print(f"Fisher exact p-value = {p_fisher:.4f}")          # 1.0000
print("Note: some expected values < 5 → Fisher's test preferred")
```

Fim da resolução da Atividade Formativa 2